

PONTIFICIA UNIVERSIDAD CATÓLICA ARGENTINA
Facultad de Humanidades y Ciencias Económicas | Lic. en Economía Empresarial

TRABAJO PRÁCTICO N° 1 — SEMANA 1

Materia: Ciencia de Datos II (GES0132) | **Carga horaria:** 2 hs reloj (Virtual Asincrónico)

Docente: Esp. Prof. Diego Vidal Silva (@diegovidalsilva)

SECCIÓN 1: APUNTE DE CÁTEDRA Y LECTURA GUIADA

¡Hola a todos y bienvenidos a la primera actividad práctica asincrónica de Ciencia de Datos II!

Si están leyendo esta guía, significa que ya compartimos nuestro primer encuentro presencial en el aula y estamos listos para poner en marcha el trabajo autónomo de esta semana. Como estudiantes de 3.er año de la Licenciatura en Economía Empresarial de la UCA, ustedes ya cuentan con un bagaje sólido: comprenden la lógica de los estados contables, las decisiones micro y macroeconómicas, el análisis estadístico descriptivo e inferencial y la sintaxis básica de Python adquirida en *Ciencia de Datos I*.

En el mercado profesional actual, las organizaciones no buscan economistas que se limiten a calcular promedios en plantillas de cálculo estáticas, ni ingenieros informáticos que programen algoritmos sin comprender los objetivos financieros o comerciales de la firma. Lo que el mercado demanda con urgencia son **'traductores estratégicos'**: profesionales capaces de tomar un problema difuso de negocios y resolverlo mediante el análisis y modelado de datos masivos. Ese es el rol de consultoría gerencial en el que nos entrenaremos.

■ El gran salto de la materia:

En *Ciencia de Datos I* respondíamos **'¿Qué ocurrió?'** (Análisis Descriptivo). En *Ciencia de Datos II* daremos un salto cualitativo hacia la **Analítica Predictiva, el Machine Learning y los productos de software** para responder: **'¿Qué va a ocurrir y qué decisión gerencial debemos tomar hoy al respecto?'**

El Ciclo de Vida de la Ciencia de Datos (La Ruta del Consultor)

Para que un proyecto analítico transforme la toma de decisiones empresariales, debemos recorrer 5 etapas continuas:

- 1. Adquisición:** Obtener datos de fuentes internas (ERP, CRM) y externas (*Open Data*, APIs de la web).
- 2. Manipulación (Data Munging):** Limpiar, imputar valores nulos (NaN) y estructurar *DataFrames* en Pandas.
- 3. Análisis y Modelado:** Entrenar algoritmos de Machine Learning enfocándonos en la **intuición lógica de negocio** por sobre la abstracción matemática dura.
- 4. Reporte (Data Storytelling):** Traducir métricas técnicas en visualizaciones e *insights* claros para el Directorio.
- 5. Acción (Data Products):** Desplegar el modelo como un software o tablero interactivo que automatice decisiones.

Preguntas para reflexionar antes de pasar al código, responder en el foro y debatir:

- 1. Diagnóstico de nulos:** Si un dataset tiene un 30% de datos faltantes, ¿por qué eliminar las filas sin analizar su causa puede introducir un sesgo grave en las decisiones de la empresa?
- 2. Rol del consultor:** ¿Cuál es la diferencia sustancial entre un analista que entrega un gráfico descriptivo y un consultor de datos que formula una recomendación estratégica?

- **3. Valor de Open Data:** ¿Por qué para un economista empresarial es más valioso consumir datos en vivo desde APIs públicas o portales abiertos que trabajar únicamente con archivos CSV estáticos creados para clase?

SECCIÓN 2: HOJA DE RUTA Y CONSIGNAS DEL TRABAJO PRÁCTICO N° 1

Objetivo General: Poner a punto tu entorno de trabajo en la nube (Google Colab), importar la librería especializada pandas, realizar la lectura de un dataset real de negocios desde un repositorio web de *Open Data* y ejecutar un Análisis Exploratorio de Datos (EDA) interpretando técnicamente sus dimensiones y estadísticos.

Modalidad de Entrega:

- **Plataforma:** Se entrega a través de la tarea habilitada en la Plataforma EVA (Moodle).
- **Formato:** Podés adjuntar el archivo descargado de tu cuaderno .ipynb o compartir el enlace público de tu copia en Google Colab con permisos de lectura.
- **Carga Horaria Estimada:** 90 minutos de trabajo individual.
- **Criterio de Evaluación:** Se evaluará la correcta ejecución del código en Python y, fundamentalmente, la profundidad de las **respuestas de reflexión de negocio** planteadas al final del cuaderno.

SECCIÓN 3: GUÍA PASO A PASO — LABORATORIO 1 EN GOOGLE COLAB

A continuación tenés la estructura exacta celda por celda para construir tu cuaderno en **Google Colab**. Abrí colab.research.google.com, crea un 'Nuevo Cuaderno', colócale de título TP1_CienciaDeDatos2_UCA_[TuApellido].ipynb y reproduce las celdas de texto y código mostradas abajo:

Celda 1 (Texto / Markdown)

Celda de Texto 1:

```
# ■ Ciencia de Datos II (GES0132) — UCA
## Trabajo Práctico N° 1: Exploración Inicial de Datos de Negocios con Pandas
Docente: Esp. Prof. Diego Vidal Silva (@diegovidalsilva)
Semana 1: Trabajo Virtual Asincrónico
```

■ Objetivos:

- Configurar y verificar el entorno virtual en la nube (Google Colab).
- Importar la librería especializada `pandas`.
- Cargar un dataset real desde un repositorio web (*Open Data*).
- Aplicar inspección estructural: `shape`, `columns`, `head()`, `info()` y `describe()`.
- Formular conclusiones de negocio sobre el fenómeno analizado.

Celda 2 (Código Python) — Importación de librerías

■ Celda de Código 1

```
# Paso 1: Importación de librerías esenciales
import pandas as pd
import numpy as np

print('■ Entorno configurado correctamente.')
print(f'Versión de Pandas instalada: {pd.__version__}')
```

Celda 3 (Texto) y Celda 4 (Código) — Ingesta de datos

Celda de Texto 2:

■ Paso 2: Carga del Dataset desde Fuente Remota (Open Data)
Cargaremos un dataset financiero real de flujo semanal de fondos e inversiones.

■ Celda de Código 2

```
# Carga de dataset remoto desde GitHub/Open Data
url_dataset =
'https://raw.githubusercontent.com/datasets/investor-flow-of-funds/master/data/weekly.csv'

# Lectura e ingesta con Pandas
df = pd.read_csv(url_dataset)
print('■ Dataset cargado exitosamente en el DataFrame df.')
```

Celda 5 (Texto) y Celda 6 (Código) — Estructura y columnas

Celda de Texto 3:

■ Paso 3: Inspección Estructural del DataFrame
Determinamos las dimensiones de la tabla (filas u observaciones x columnas o variables).

■ Celda de Código 3

```
# Inspección de forma (filas, columnas)
filas, columnas = df.shape
print(f'Dimensiones: {filas} filas y {columnas} columnas.\n')

# Lista de variables disponibles
print('Variables en el dataset:')
print(df.columns.tolist())
```

Celda 7 (Texto) y Celda 8 (Código) — Exploración inicial con head()**Celda de Texto 4:**

■ Paso 4: Muestra de Registros Iniciales

Visualizamos los primeros 5 registros de la tabla para entender el formato de los datos.

■ Celda de Código 4

```
# Muestra inicial de las primeras 5 observaciones
df.head()
```

Celda 9 (Texto) y Celda 10 (Código) — Diagnóstico técnico con info()**Celda de Texto 5:**

■ Paso 5: Diagnóstico de Tipos de Datos y Valores Nulos

Analizamos si las columnas son numéricas o de texto y verificamos la presencia de datos faltantes.

■ Celda de Código 5

```
# Resumen técnico de tipos de datos y valores no nulos
df.info()
```

Celda 11 (Texto) y Celda 12 (Código) — Estadísticos con describe()**Celda de Texto 6:**

■ Paso 6: Estadísticos Descriptivos de Negocio

Calculamos la media, desvío estándar, mínimos, máximos y percentiles cuantitativos.

■ Celda de Código 6

```
# Resumen de métricas de tendencia central y dispersión
df.describe().T
```

■ CUESTIONARIO OBLIGATORIO DE REFLEXIÓN DE NEGOCIO

En la última celda de tu cuaderno de Google Colab (Celda de texto / Markdown), edita y responde en detalle las siguientes tres preguntas analíticas. Recuerda que no evaluamos sólo la ejecución del código, sino tu criterio gerencial:

Pregunta de Reflexión	Guía de Respuesta / Criterio Esperado
1. Interpretación del Fenómeno: En función de los nombres de columnas observados en <code>df.columns</code> y los primeros registros de <code>df.head()</code> , ¿qué fenómeno económico/financiero representa este dataset?	Identificar que el dataset registra el flujo semanal de fondos de inversión (equity, bonos, money market). Explicar en 2 oraciones qué representa cada columna en términos de liquidez.
2. Diagnóstico Técnico de Calidad: Al analizar la salida de <code>df.info()</code> , ¿detectas inconsistencias en los tipos de datos (ej. fechas tratadas como texto) o presencia de valores nulos?	Señalar qué columnas tienen valores faltantes y verificar si la variable temporal (fecha) requiere ser convertida con <code>pd.to_datetime()</code> en etapas posteriores.

3. Criterio Gerencial vs. Promedios:

Supongamos que este reporte llega al Director Financiero. ¿Por qué considerar únicamente la media (mean) ignorando el desvío estándar (std) o la variabilidad puede conducir a decisiones erróneas?

Demostrar pensamiento crítico: la media puede estar distorsionada por semanas atípicas o volátiles. El desvío estándar mide el riesgo y la volatilidad real del flujo de fondos.

¡Éxitos en el desarrollo del TP1! Si tenés dudas técnicas sobre el código o las consignas, recordá dejar tu consulta abierta en el grupo oficial de WhatsApp de la materia.