

 GUÍA DEL LABORATORIO VIRTUAL N° 3

Materia: Ciencia de Datos II

Actividad: Laboratorio Virtual N° 3 — Proceso ETL Masivo y Calidad del Dato con OpenRefine

Herramienta de Trabajo: OpenRefine

Carga Horaria Estimada: 90 minutos

Formato de Entrega: Archivo JSON con el historial de operaciones de OpenRefine (Export -> *Undo/Redo* -> *Extract history*) y el dataset final limpio exportado en formato `.csv`.

 Objetivo de la Actividad

Asumirán el rol de **Consultor Senior de Datos** en una fintech argentina. Se les ha provisto un volcado en bruto del sistema de transacciones (`clientes_sucio_1000.csv`) que contiene duplicados, nulos graves, errores humanos de tipeo, múltiples formatos de fecha y columnas distractoras. Su misión es diseñar y ejecutar un flujo **ETL (Extracción, Transformación y Carga)** en **OpenRefine** para depurar la base de datos y dejarla 100% óptima para el directorio financiero.

 Secuencia de Consignas Paso a Paso (Instrucciones para el Estudiante) **Paso 1: Inicialización del Proyecto**

1. Descarguen el archivo `clientes_sucio_1000.csv` provisto por la cátedra.
2. Inicien **OpenRefine**, seleccionen **Crear proyecto** -> **Este ordenador** y carguen el archivo.
3. En la pantalla de previsualización, verifiquen que la **Codificación del carácter** esté configurada en **UTF-8** para que reconozca correctamente las tildes y caracteres en español.
4. Hagan clic en **Crear proyecto** en la esquina superior derecha, asignándole el nombre: `ETL_Fintech_Apellido_Nombre`.

 Paso 2: Limpieza de Columnas Distractoras

1. Identifiquen las dos columnas que actúan como "ruido analítico" y no aportan valor para clasificar perfiles de crédito (columnas de ID de sesión y preferencias visuales).
2. Elimínenlas de forma permanente utilizando el menú de la primera columna general: **Todo** -> **Editar columnas** -> **Reordenar / eliminar columnas**. En la ventana emergente, arrastren las columnas distractoras hacia el cuadro de la derecha para descartarlas.

Paso 3: Control de Duplicados Puros

1. Detecten y eliminen las filas duplicadas exactas de la base de datos utilizando como criterio la columna clave del ID: desplegando el menú de **id_cliente** -> **Ordenar...** -> seleccionen ordenar como **número** y hagan clic en **Aceptar**.
2. Para fijar este orden en el dataset, hagan clic en el nuevo menú **Ordenar** que apareció en la barra superior de la grilla de datos y elijan **Reordenar filas permanentemente**.
3. Una vez ordenadas, si elijen eliminarlas, utilicen la opción sobre la misma columna clave: **id_cliente** -> **Editar celdas** -> **Vaciar en blanco hacia abajo** (*Blank down*).
4. Finalmente, para eliminar estas filas que ahora quedaron vacías (que representan los duplicados), apliquen un filtro sobre **id_cliente** -> **Faceta** -> **Faceta por valores nulos** (*Facet by null*). En el panel izquierdo, seleccionen **true** (que filtrará solo las celdas vacías) y eliminen esas filas mediante: **Todo** -> **Editar filas** -> **Eliminar todas las filas coincidentes**. Al cerrar la faceta de nulos, les quedará el dataset limpio de redundancias.

Paso 4: Estandarización de Sucursales (El Poder del Clustering)

La columna **sucursal_registro** es un caos de tipeo manual (ej: *Mendoza, MENDOZA, Mendza, Maipú, maipu*, etc.).

1. Desplieguen el menú de **sucursal_registro** -> **Faceta** -> **Faceta de texto** para ver la distribución en el panel izquierdo.
2. En ese mismo menú de columna, ingresen a: **Editar celdas** -> **Agrupar y editar...** (*Cluster and edit*).
3. Experimenten con al menos dos métodos de agrupación:
 - Método: **Colisión de claves** (*Key Collision*) / Función de clave: **Huella digital** (*Fingerprint*).
 - Método: **Vecino más cercano** (*Nearest Neighbor*) / Función de distancia: **Levenshtein**.
4. Fusionen de forma coherente las variantes que el algoritmo identifique seleccionando la casilla **¿Agrupar?** y escribiendo el nombre correcto en **Nuevo valor de la celda**, consolidando únicamente **4 sucursales oficiales**: **Mendoza**, **San Rafael**, **Godoy Cruz** y **Maipú**. Hagan clic en **Agrupar y cerrar**.

 Paso 5: Tratamiento de Outliers (Edades e Ingresos)

1. Transformen las columnas numéricas para que la herramienta las reconozca como tal: menú de **edad_declarada** e **ingreso_mensual_ars** -> **Editar celdas** -> **Transformaciones comunes** -> **A número**.
2. Apliquen una faceta de control en **edad_declarada** -> **Faceta** -> **Faceta numérica**. En los gráficos de barras del panel izquierdo, detecten los valores extremos biológicamente imposibles (valores bajo cero o excesivamente altos superiores a 100 años). Corrijan o dejen en blanco estas celdas editando directamente el registro individual haciendo clic en el botón **editar** al lado del valor.
3. Analicen la columna **ingreso_mensual_ars**. Utilicen filtros o facetas de texto para identificar el impacto de los registros que contienen el texto "*No declara*" y resuelvan cómo tratarlos para no romper el análisis numérico. Detecten y corrijan el error de tipeo extremo de caja (\$9.999.999) mediante un filtro personalizado de celdas o editando el valor de forma justificada.

 Paso 6: Homogeneización de Fechas

1. La columna **fecha_inscripcion** cuenta con formatos de carga inconsistentes. Utilicen la función de transformación temporal: **fecha_inscripcion** -> **Editar celdas** -> **Transformaciones comunes** -> **A fecha**.
2. Esto estandarizará todos los registros válidos al formato ISO internacional de fecha y tiempo. Identifiquen las celdas que no pudieron ser convertidas (que permanecen en verde o se muestran como texto) para auditar la calidad temporal de la base de datos.

 ¿Cómo extraer y entregar el historial de OpenRefine?

Para completar la entrega de la tarea, los estudiantes deberán hacer lo siguiente:

1. En el panel izquierdo, ir a la pestaña **Deshacer / Rehacer**.
2. Hacer clic en el botón **Extraer...** (*Extract*).
3. Copiar todo el código JSON que aparece en el cuadro de la derecha (que contiene el historial ordenado de cada transformación que realizaron en el laboratorio).
4. Pegar ese código en un archivo de texto llamado **historial_operaciones.json** y subirlo a Moodle junto con el dataset final limpio exportado en formato **CSV** utilizando el botón de arriba a la derecha: **Exportar** -> **Valores separados por comas (CSV)**.

 Cuestionario Obligatorio de Criterio de Negocio (Para el entregable)

Para aprobar el laboratorio, deberán adjuntar un archivo de Word con las respuestas estratégicas a estas tres preguntas:

1. **El Criterio del Clustering:** Expliquen detalladamente qué diferencia observaron entre el algoritmo de clusterización *Fingerprint* (colisión de llaves) y el algoritmo *Levenshtein* (distancia de caracteres) al unificar las sucursales. ¿Cuál detectó más errores de tipeo y por qué?
2. **Estrategia Financiera ante el "No declara":** En la columna de ingresos, se presentaba la etiqueta textual "*No declara*". Si un analista junior decidiera transformar esa celda a un 0 de forma automatizada antes de pasarlo a un modelo de scoring de crédito: ¿qué error gerencial gravísimo estaría cometiendo con respecto a la evaluación del cliente?
3. **Auditoría del Historial:** ¿Por qué la posibilidad de OpenRefine de extraer el historial de operaciones en formato JSON (*Undo/Redo*) es un pilar fundamental para garantizar la **reproducibilidad y el gobierno de datos** en una auditoría corporativa?